

Martín,

Excelente trabajo durante todo el curso. Tu trabajo de laboratorio individual fue muy bueno. Tu participación en clases y en el debate estuvieron a la altura de lo que se espera para un curso de posgrado.

El trabajo tiene muchísimo potencial para evolucionar a paper porque la pregunta de investigación es muy buena y entiendo muy original: estudiar si la similitud funcional inducida por knowledge distillation preserva mecanismos internos y explicativos en Transformers autoregresivos.

Además, los resultados son interesantes. De hecho, que los estudiantes logren buen desempeño pero no preserven explicaciones ni estructuras internas fuertes es un hallazgo.

Para que esto evolucione a publicación, hay varios puntos que te recomendaría trabajar:

- Incorporar líneas base (fundamental, vos mismo lo reconoces en el trabajo). Hoy no podés concluir cuánto del comportamiento observado viene realmente de la destilación y cuánto simplemente de entrenar un modelo más chico. Necesitás se me ocurre, un estudiante entrenado SIN distillation (solo CE), y alguna variante con distinto peso de KL.
- Pasar de ejemplos cualitativos a evaluación sistemática. Actualmente LIME/SHAP/IG están evaluados sobre pocos ejemplos y de forma bastante visual (muy bien para el trabajo final del curso). Para paper necesitás métricas agregadas: correlación entre atribuciones, overlap de top-k tokens, rank correlation, faithfulness, estabilidad, agreement profesor-estudiante.
- Separar claramente performance de alignment interno. El resultado más interesante del trabajo es justamente que mejor accuracy no implica mayor similitud representacional. S2 clasifica mucho mejor que S1, pero tiene KL global peor. Eso es muy interesante conceptualmente y habría que seguirlo.
- Profundizar el análisis representacional. Ahí podrías:
 - comparar embeddings y hidden states además de attention,
 - analizar por head en vez de solo promedios,
 - medir si las primeras capas preservan información léxica y las profundas divergencias semánticas.
- Evaluar más datasets/tareas. IMDb está bien como prueba inicial y para el trabajo final, pero para paper probablemente necesites otra tarea de clasificación, quizás una tarea no binaria?
- Discutir limitaciones conceptuales de XAI. Esto también puede enriquecer muchísimo el paper: si LIME/SHAP dicen cosas inconsistentes pero el modelo funciona, ¿el problema es la destilación? ¿o lo son los métodos de explicación?
- Finalmente, venderlo mejor. No presentarlo como “Aplicamos XAI a distillation”, sino algo parecido a “Functional similarity does not imply explanatory or representational alignment in distilled autoregressive transformers.”

Excelente trabajo, felicitaciones!