

Architecture reduction

Teacher

22 layers - fine-tuned

Embeddings

layer 0

layer 1

layer 2

layer 3

layer 4

layer 5

layer 6

layer 7

⋮

layer 20

layer 21

LM head

Student

11 layers - random init

Embeddings (random)

layer 0 (random)

layer 1 (random)

layer 2 (random)

layer 3 (random)

⋮

layer 11 (random)

LM head (random)